

ENTREGA FINAL - Ecosistema de Automatización IA para Atención al Cliente

Caso de uso: Gestión de consultas recibidas por una empresa de automatización con IA via email.

El objetivo es agilizar la atención inicial de clientes que realizan consultas comerciales, de soporte técnico o informativas.

Alcance. La automatización abarca el proceso desde la recepción de la consulta hasta la generación y envío de una respuesta, incorporando clasificación, priorización y control humano antes del contacto final con el cliente.

Orquestador: Make

Base de datos: Notion


Procesamiento IA: Cohere (Modelo Command A)

Canal de salida: Gmail

Nota sobre el motor de IA. Para este proyecto se utilizó Cohere como motor de procesamiento de lenguaje natural. Su utilización fue previamente autorizada por los docentes de esta cursada como alternativa válida a OpenAI/Anthropic, con el objetivo de evitar costos adicionales y reducir riesgos asociados al uso de cuentas o credenciales personales.

1. Mapa de Arquitectura

El mapa representa la arquitectura de los dos escenarios implementados y el recorrido de los datos entre sus componentes. Incluye el trigger de entrada, la validación inicial, el procesamiento mediante IA, la persistencia y actualización de datos en Notion, la ruta de manejo de errores y el punto de control humano (HITL) previo al envío de la respuesta por Gmail.



2. Estructuras de Datos Documentadas

Esquema de tablas vinculadas en Notion

La base de datos del sistema fue construida en **Notion** y funciona como memoria y registro de la automatización. Está compuesta por dos tablas vinculadas: **Clientes** y **Consultas IA**, diseñadas para almacenar por separado la información del cliente y las consultas que ingresan al sistema.

La tabla **Clientes** concentra la información básica de cada cliente. La tabla **Consultas IA** registra las consultas recibidas por email y los datos que se generan durante su procesamiento, como categoría, prioridad, respuesta de IA, estado, aprobación humana, errores y datos de trazabilidad.

Ambas tablas están vinculadas mediante una relación **1:N (uno a muchos)**: un cliente puede tener varias consultas asociadas y cada consulta se vincula con un cliente. La relación es bidireccional, por lo que desde **Clientes** pueden visualizarse sus consultas asociadas y desde **Consultas IA** puede identificarse el cliente correspondiente.

Esta estructura evita mantener la información de clientes y consultas como datos aislados y permite conservar un historial organizado de las interacciones procesadas por el sistema.

Tabla de Notion: Clientes

Campos principales: Nombre, Email, Consultas IA (relación)

Función dentro del sistema: Registra los datos básicos del cliente y permite acceder a las consultas asociadas.

Tabla de Notion: Consultas IA

Campos principales: Nombre, Fecha, Email, Consulta, Estado, Categoría, Prioridad, Respuesta IA, Aprobado, Error, Cliente, Thread ID, Message ID

Función dentro del sistema: Registra cada consulta y los datos generados durante su procesamiento, aprobación, envío y gestión de errores.

Esquemas JSON de transferencia de las integraciones

Los siguientes esquemas JSON documentan la transferencia de datos entre las integraciones que componen el flujo. En cada caso se identifican los principales campos que un módulo recibe, procesa o utiliza como entrada para el siguiente paso de la automatización.

Gmail → Notion

```
{  
  
  "nombre": "{{2.subject}}",  
  
  "email": "{{2.fromEmail}}",  
  
  "consulta": "{{2.snippet}}",  
  
  "estado": "Pendiente",  
  
  "aprobado": false,  
  
  "fecha": "{{2.internalDate}}",  
  
  "thread_id": "{{2.threadId}}",  
  
  "message_id": "{{2.headers.Message-ID}}"
```

```
}
```

Explicación: Cuando Gmail detecta un nuevo correo, Make crea un registro en Notion con los datos principales de la consulta. El asunto se utiliza como nombre del registro, se conserva el email del remitente, la consulta se almacena mediante **Snippet**, se registra la fecha y se guardan **Thread ID** y **Message ID** para trazabilidad. El registro se crea inicialmente con estado **Pendiente** y **Aprobado = false**. Todo esto coincide con los mapeos exportados en el Blueprint del Escenario 1.

Gmail → Cohere

```
{
```

```
  "consulta_cliente": "{{2.fullTextBody}}",
```

```
  "model": "command-a-03-2025",
```

```
  "max_tokens": 150,
```

```
  "response_format": "text",
```

```
  "temperature": 0.75,
```

```
  "top_p": 0.75
```

```
}
```

Explicación: El cuerpo completo del email se inserta dinámicamente dentro del prompt enviado a Cohere. El modelo utilizado es **command-a-03-2025**, con un máximo de 150 tokens de salida y formato de respuesta en texto. Esta transferencia permite que el modelo analice el contenido completo de la consulta antes de generar la clasificación y la respuesta.

Cohere → Notion

```
{
```

```
  "respuesta_ia": "{{9.text}}",
```

```
  "estado": "Pendiente de aprobación"
```

```
}
```

Explicación: Si Cohere responde correctamente, Make actualiza el mismo registro de Notion con el texto generado por la IA y cambia su estado a **Pendiente de aprobación**. A partir de ese momento, la consulta queda detenida hasta recibir la validación humana.

Notion → Gmail

```
{
```

```
  "condicion_envio": {
```

```
    "estado": "Pendiente de aprobación",
```

```
    "aprobado": true
```

```
  },
```

```
  "to": "{{2.properties_value.Email}}",
```

```
  "subject": "Respuesta a tu consulta",
```

```
  "content": "{{2.properties_value.Respuesta IA[.plain_text}}"
```

```
}
```

Explicación: En el segundo escenario, Gmail solo recibe los datos cuando el filtro HITL confirma que el registro continúa en **Pendiente de aprobación** y que **Aprobado = true**. El destinatario se obtiene desde Notion y el cuerpo del correo utiliza el texto plano de **Respuesta IA**. Después del envío, Make actualiza ese mismo registro en Notion con:

```
{
  "estado": "Enviado"
}
```

De esta manera, el sistema deja registrado que la acción crítica ya fue ejecutada.

Ruta de error: Cohere → Notion

```
{
  "estado": "Error",
  "error": "{{9.error.message}}"
}
```

Explicación: Si el módulo de Cohere falla, la ruta **onerror** actualiza el mismo registro creado previamente en Notion. El estado se asigna a **Error** y el detalle técnico se obtiene dinámicamente desde **{{9.error.message}}**. Después de ese registro se ejecuta la directiva **Resume**.

3. Optimización de costos

Para seleccionar el modelo de IA se consideraron el **tipo de tarea, el costo de procesamiento y la necesidad de respuesta en tiempo real**. El sistema procesa consultas breves por email y debe clasificarlas, asignar una prioridad y generar una respuesta, por lo que se compararon las siguientes alternativas:

Modelo / estrategia	Uso recomendado	Costo de referencia*	Decisión para el proyecto
Cohere Command A	Clasificación, priorización y generación de respuestas	Trial API gratuita y limitada. Producción: USD 2,50/M input · USD 10/M output	Seleccionado. La Trial API permite desarrollar y validar el proyecto sin costo de procesamiento, además permite resolver las tres tareas en una única llamada y tiene soporte multilingüe.
GPT-5 mini	Tareas breves, estructuradas y de alto volumen	USD 0,25/M input · USD 2/M output	Alternativa de menor costo por token para una implementación con mayor volumen.
Claude Haiku 4.5	Clasificación y generación de respuestas breves	USD 1/M input · USD 5/M output	Alternativa intermedia en costo para este tipo de procesamiento.

Batch API	Procesamiento masivo no urgente	Descuento según proveedor	No se utiliza porque las consultas se procesan individualmente. Sería una opción para análisis históricos o grandes volúmenes que no requieran respuesta inmediata.
------------------	---------------------------------	---------------------------	---

Decisión: Se utiliza **Cohere Command A** porque, para la etapa de desarrollo y prueba del sistema, su Trial API permite validar el flujo sin costo de procesamiento dentro de sus límites de uso. Además, una única llamada al modelo resuelve las tres tareas requeridas: **clasificación, asignación de prioridad y generación de la respuesta**. Si el sistema pasara a producción con un volumen mayor, el costo por token tendría más peso y sería conveniente reevaluar la elección frente a alternativas más económicas como GPT-5 mini. Como medida adicional de optimización, la salida se limita a **150 Max Tokens** y el prompt establece respuestas de hasta **70 palabras**.

*Valores de referencia de API consultados en la documentación oficial de cada proveedor.

4. Seguridad y resiliencia

Minimización de datos

El flujo almacena en Notion únicamente la información necesaria para gestionar cada consulta: datos básicos del remitente, una versión resumida del contenido mediante **Snippet**, estado, respuesta generada, aprobación, error y datos de trazabilidad. El cuerpo completo del email se utiliza para el procesamiento de IA, pero no se conserva íntegramente en la base de datos.

Esta decisión reduce la cantidad de información persistida y limita el almacenamiento a los datos necesarios para operar y auditar el sistema.

Rutas de error (Error Handler)

El módulo de Cohere cuenta con una ruta de **Error Handler**. Si la API de IA falla, Make deriva la ejecución hacia una actualización en Notion que registra el detalle técnico del error mediante **Error.Message**.

La ruta finaliza con la directiva **Resume**, permitiendo que el escenario gestione la excepción sin detener por completo la ejecución. El error queda registrado en la base para su posterior revisión y monitoreo.

Human-in-the-Loop (HITL)

Después de generar la respuesta, el sistema cambia el estado de la consulta a **Pendiente de aprobación**. En ese punto la automatización espera una validación humana antes de ejecutar el envío al cliente.

El segundo escenario solo continúa cuando se cumplen ambas condiciones:

Estado = Pendiente de aprobación
Aprobado = true

Si la consulta no fue aprobada, el flujo no realiza la acción crítica. Una vez aprobada, Gmail envía la respuesta y Notion actualiza el estado a **Enviado**.

5. Dashboard de Control

El Dashboard se implementó como una **Shared View pública de Notion**, orientada al monitoreo de las ejecuciones del sistema. El encabezado resume los principales KPIs del ciclo de prueba: **total de consultas, enviadas, pendientes, errores y tasa de errores**. Además, las distintas vistas permiten inspeccionar los registros por **estado, categoría y prioridad**, facilitando el seguimiento del funcionamiento del flujo.

Enlaces:

Dashboard / Shared View: [Abrir Dashboard de KPIs en Notion](#)

Base de datos Consultas IA - modo lectura: [Abrir Consultas IA en Notion](#)